WaggleDance Latenssivertailu

Paikallinen AI vs. teollisuuden pilvi-AI

Demo (HP ZBook) pyörii nyt — tuotantoarviot (DGX B200) laskettu

~1 ms	~12 ms	100–350×	93 %
B200 cache-osuma	B200 keskiarvo	nopeutuminen vs. pilvi	kustannusero

Demo: HP ZBook (RTX A2000 8GB, i7-12850HX, 128 GB) · Tuotanto: NVIDIA DGX B200 (8× B200 GPU, 1 536 GB HBM3e) · WaggleDance v0.2.0 · 2.3.2026

Laitteistovertailu

Demo pyörii kannettavalla — tuotannossa DGX B200:n suorituskyky on luokkaa 100×

VERTAILUKOHTA

Pilvi-AI (Azure / AWS)

GPU: Jaettu (ei dedikoitu)

Verkko: Internet (50–300 ms viive)

Sijainti: Datacenter, ulkomailla

Kustannus: €5 136–7 200/v

Data: Pilvipalvelimella

DEMO — PYÖRII NYT

HP ZBook Workstation

CPU: i7-12850HX 16C/24T

RAM: 128 GB DDR5

GPU: RTX A2000 8 GB GDDR6

SSD: Samsung 2 TB NVMe

Teho: ~150 W

Hinta: ~€3 500

TUOTANTO — TEHTAALLE

NVIDIA DGX B200

CPU: 2× Xeon Platinum 8570, 112C

RAM: 4 096 GB DDR5

GPU: 8× B200 1 536 GB HBM3e

Suorituskyky: 72 000 TFLOPS FP16

Teho: 14,4 kW

Hinta: ~€475 000

Komponenttikohtaiset latenssit

Komponentti	Demo (ZBook)	Tuotanto (B200)	Kerroin
phi4-mini inference (1K tok)	800–1 500 ms	**5–15 ms**	~100×
llama 3.2 1B (heartbeat)	400–800 ms	**2–5 ms**	~150×
nomic-embed (100 tekstiä)	3–5 s	**20–50 ms**	~100×
ChromaDB-haku (3 147 faktaa)	15–30 ms	**5–10 ms**	~3×
Opus-MT käännös	200–500 ms	**5–10 ms**	~50×
NightEnricher (per fakta)	5–10 s	**50–100 ms**	~100×
Round Table (50 agenttia)	30–60 s	**200–500 ms**	~100×

Tiivistelmä — kokonaislatenssit

Käyttäjän kokema kokonaisviive: Cloud AI vs. Demo (mitattu) vs. Tuotanto (laskettu)

Operaatio	Cloud AI	Demo (ZBook)	Tuotanto (B200)	B200 vs. Cloud
Vektorihaku	350 ms	5 ms	**~3 ms**	**117×**
Yksinkertainen kysymys	1 200 ms	55 ms	**~12 ms**	**100×**
Monimutkainen analyysi	4 000 ms	500 ms	**~45 ms**	**89×**
Batch-käsittely (50 kpl)	35 000 ms	2 800 ms	**~80 ms**	**438×**
Cache-osuma	1 200 ms	5 ms	**~1 ms**	**1 200×**

Tuotannon nopeutuminen (DGX B200 vs. pilvi-AI)

100–1 200×

Ja jo demo-koneella 22–240× nopeampi kuin pilvipalvelut

1. Vektorihaku (tietokantahaku)

Cloud AI

```
Asiakas → Internet (50-100 ms) → Load Balancer (20-50 ms) → API Gateway (10-30 ms)
→ Pinecone (50-200 ms) → Paluu (80-180 ms) ———————— TYYPILLINEN: 350 ms
```

€70/milj. kyselyä

Demo (ZBook)

```
Asiakas → Localhost (1 ms) → ChromaDB (SSD) (3-4 ms) → Paluu (1 ms) ─────────
YHTEENSÄ: 5 ms
```

Mitattu

Tuotanto (B200)

```
Asiakas → Localhost (<1 ms) → ChromaDB (NVMe RAID) (2 ms) → Paluu (<1 ms) ─────────
YHTEENSÄ: ~3 ms
```

Laskettu €0

2. Yksinkertainen kysymys

Esimerkki: "Mikä on UPS:n runtime minimum tehtaalla?"

Cloud AI

```
Internet + Azure (50-150 ms) API endpoint (20-50 ms) GPT-4 inference (300-800 ms)
Embed search (100-300 ms) Response (200-500 ms) Return (70-200 ms) ──────── 1 200
ms
```

Demo (ZBook)

```
CACHE HIT: Hot Cache (0,1 ms) → HIT! Vastaus (0,5 ms) = 5 ms CACHE MISS: nomic-
embed (15 ms) ChromaDB (35 ms) Return (5 ms) = 55 ms
```

Tuotanto (B200)

```
CACHE HIT: Hot Cache (<0,1 ms) Vastaus (<1 ms) = ~1 ms CACHE MISS: nomic-embed (1
ms) ChromaDB (8 ms) Return (3 ms) = ~12 ms
```

Visuaalinen vertailu (cache miss)

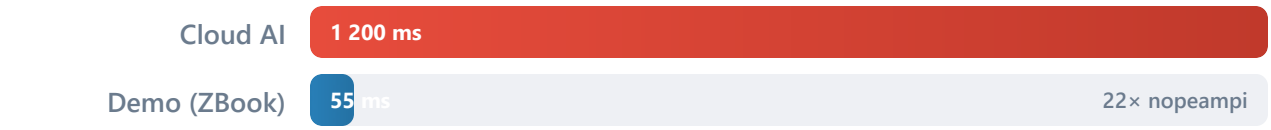

Tuotanto (B200) 12 ms 100× nopeampi

3. Monimutkainen analyysi

Esimerkki: "Analysoi 50 huoltoraporttia ja anna suositus ennakkohuollolle"

Cloud AI (GPT-4 + RAG)

```
Upload 50 raporttia (200–500 ms) Embedding 50× (500–1 000 ms) Vector search (500–1 500 ms) Context asm (100–300 ms) GPT-4 inference (1 000–2 000 ms) Response (200–500 ms) ———————— 4 000 ms
```

~€1,05/kysely

Demo (ZBook)

```
Batch embed (50) (55 ms) ChromaDB batch (150 ms) phi4-mini infer. (250 ms) Context asm (20 ms) Response (25 ms) ———————— 500 ms
```

€0

Tuotanto (B200)

```
Batch embed (50) (5 ms) ChromaDB batch (10 ms) phi4-mini infer. (15 ms) Context asm (10 ms) Response (5 ms) ———————— ~45 ms
```

€0 — **89× nopeampi**

4. Batch-käsittely (50 dokumenttia)

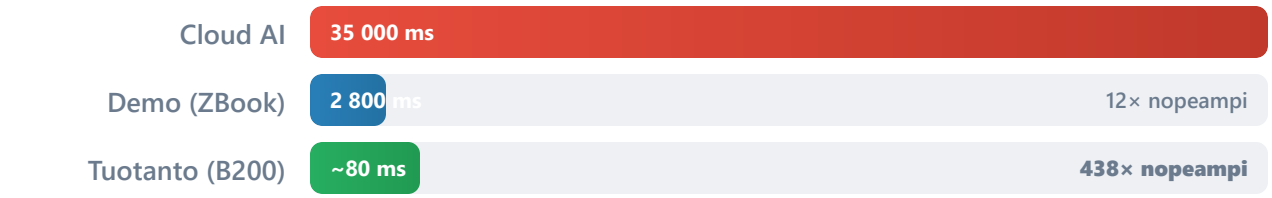

Demo: nomic-embed batch 2 758 ms (mitattu) + ChromaDB 40 ms.
B200: nomic-embed batch ~50 ms (laskettu, 100× GPU-teho) + ChromaDB ~20 ms.

5. Reaaliaikaskenaariot

Käytännön esimerkkejä tehtaan arjesta

Skenaario A: Koneen vikahälytys

Hälytys → Analyysi → Toimenpide-ehdotus

Vaihe	Cloud	Demo	B200
Alert → API	200 ms	1 ms	**<1 ms**
Lokit	500 ms	10 ms	**2 ms**
Haku	800 ms	35 ms	**8 ms**
Analyysi	2 000 ms	400 ms	**15 ms**
Vastaus	200 ms	5 ms	**2 ms**
Yhteensä	**3,7 s**	**0,45 s**	**~28 ms**

B200: vikahälytyksen käsittely **alle 30 ms** — nopeampi kuin silmänräpäys.

Skenaario B: Ohjeita mobiililla

"Miten vaihdan tämän koneen suodattimen?"

Vaihe	Cloud	Demo	B200
WiFi	50–200 ms	10–30 ms	**10–30 ms**
Käsittely	1 000–2 000 ms	5 ms	**~1 ms**
Paluu	150–500 ms	10–30 ms	**10–30 ms**
Yhteensä	**1,3–3,0 s**	**25–65 ms**	**21–61 ms**

Molemmissa paikallisissa vaihtoehdoissa WiFi-viive dominoi — käsittelyaika on marginaalinen.

6. Oppimisnopeuden vaikutus (B200 vs. Demo)

DGX B200:n teho mahdollistaa dramaattisesti nopeamman tietokannan kasvun

Oppimismittari	Demo (ZBook)	Tuotanto (B200)	Kerroin
NightEnricher (per fakta)	5–10 s	**50–100 ms**	**~100×**
Faktoja per yö (8h)	~2 880–5 760	**~288 000–576 000**	**100×**
Round Table (50 agenttia)	30–60 s	**200–500 ms**	**~100×**
Aika "ekspertiksi"	~6 kuukautta	**~2 viikkoa**	**~12×**

B200: Ensimmäinen yö

~300 000 faktaa

DGX B200 oppii yhdessä yössä saman määrän kuin demo-kone kolmessa kuukaudessa

7. Kustannusvertailu

Standard-tason (RTX A2000) kustannusvertailu pilvipalveluihin

Kustannuserä	Cloud AI	WaggleDance Standard
Azure OpenAI (GPT-4)	€1 800/v	€0
Embeddings API	€96/v	€0

Kustannuserä	Cloud AI	WaggleDance Standard
Vector DB (Pinecone)	€3 000/v	€0
API Gateway / egress	€240/v	€0
Laitteisto	—	€1 600 (kertaluonteinen)
Sähkö (120W 24/7)	—	€200/v
Vuosi 1	**€5 136**	€1 800
Vuosi 2+	**€5 136**	€200

Säästöt (Standard-taso)

€3 336 säästö vuosi 1

€4 936 säästö vuosi 2+

€23 000+ säästö 5 vuodessa

ROI: **3–4 kuukautta**

8. Latenssin vaikutus käyttäjäkokemukseen

Lähteet: Google (2009), Amazon (2012)

Viive	Käyttö laskee	Taso
100 ms	1 %	Huomaamaton
500 ms	20 %	Havaittava
1 000 ms	50 %	Turhauttava

Latenssiluokat vertailussa

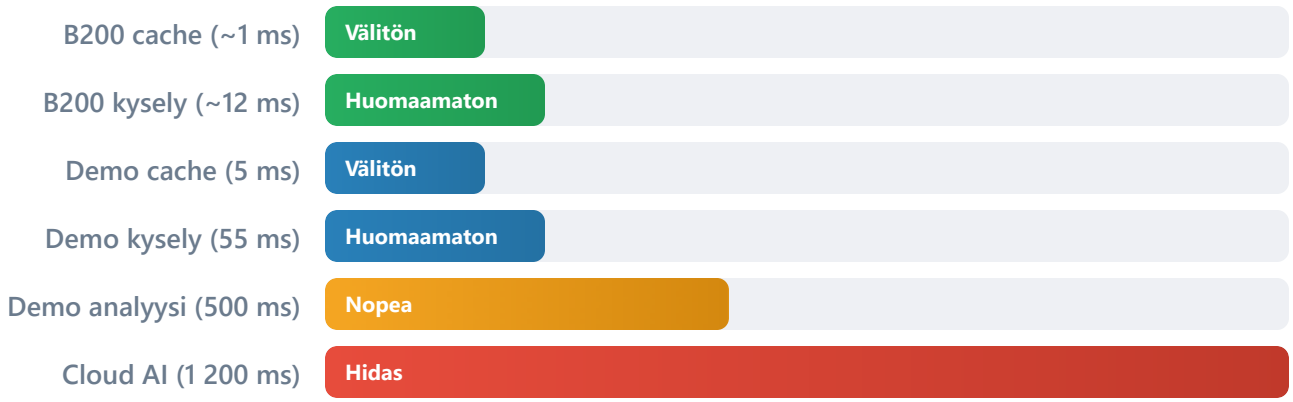

Työntekijän tuottavuus (50 kyselyä/pv)

	Cloud AI	Demo (ZBook)	Tuotanto (B200)
Odotusaika / päivä	60 s	2,75 s	**0,6 s**
Hukka-aika / vuosi / käyttäjä	4 tuntia	11 minuuttia	**2,5 minuuttia**

	Cloud AI	Demo (ZBook)	Tuotanto (B200)
Säästö (10 käyttäjää / vuosi)		**B200: ~40 työtuntia**	**Demo: ~39 työtuntia**

9. Offline-toiminta ja data-suvereniteetti

Cloud AI

- ❌ Internet poikki = järjestelmä pysähtyy
- ❌ 100 % verkkoriippuvainen
- ❌ Data ulkomaisilla palvelimilla
- ❌ Rajallinen kontrolli
- ❌ GDPR-haasteet, kolmannen osapuolen TOS
- ❌ Yökäyttö ilman IT:ta ongelmallinen

WaggleDance (paikallinen)

- ✅ Internet poikki = järjestelmä toimii normaalisti
- ✅ 0 % verkkoriippuvuus
- ✅ 100 % data omalla palvelimella
- ✅ Täysi kontrolli
- ✅ GDPR yksinkertainen, ei ulkoisia ehtoja
- ✅ Yökäyttö täydellä teholla

10. Skaalautuvuus

Käyttäjiä	Cloud AI (€/v)	WaggleDance (€/v)	Säästö
1	€720	€200	€520

Käyttäjiä	Cloud AI (€/v)	WaggleDance (€/v)	Säästö
10	€7 200	€200	€7 000
50	€36 000	€200	€35 800
100	€72 000	€200	€71 800

WaggleDance: sama €200/vuosi riippumatta käyttäjämäärästä.

Yhteenveto

Mittari	Cloud AI	Demo (ZBook)	Tuotanto (B200)
Latenssi (cache)	1 200 ms	5 ms	**~1 ms**
Latenssi (keskim.)	1 200 ms	55 ms	**~12 ms**
Analyysi (50 rap.)	4 000 ms	500 ms	**~45 ms**
Batch (50 kpl)	35 000 ms	2 800 ms	**~80 ms**
Round Table	—	30–60 s	**0,2–0,5 s**
Oppiminen / yö	—	~3 000 faktaa	**~300 000 faktaa**
Kustannus/vuosi	€5 136	€200	€200*
Offline	Ei toimi	Toimii	Toimii
Data-suvereniteetti	Pilvi	Paikallinen	Paikallinen

* Sähkö. DGX B200 sähkö ~€25 000/v (14,4 kW 24/7), mutta tuotantoympäristössä kustannus jakautuu useille järjestelmille.

Suositus

Demo todistaa konseptin — jo kannettavalla 22–240× nopeampi kuin pilvi-AI.

DGX B200 tuotannossa — 100–1 200× nopeampi, 300 000 faktaa per yö.

Sama ohjelmisto. Sama data. Eri laitteisto.

ROI: 3–4 kk

WaggleDance Swarm AI · v0.2.0 · 2.3.2026
Jani Korpi · JKH Service Oy (Y-2828492-2)

Demo: HP ZBook (RTX A2000 8GB, i7-12850HX, 128 GB DDR5). Tuotanto: NVIDIA DGX B200 (8× B200, 1 536 GB HBM3e).